Практический анализ данных и машинное обучение: искусственные нейронные сети

Ульянкин Филипп, Соловей Влад

2 июня 2019 г.

Введение в RL

Reinforcement Learning

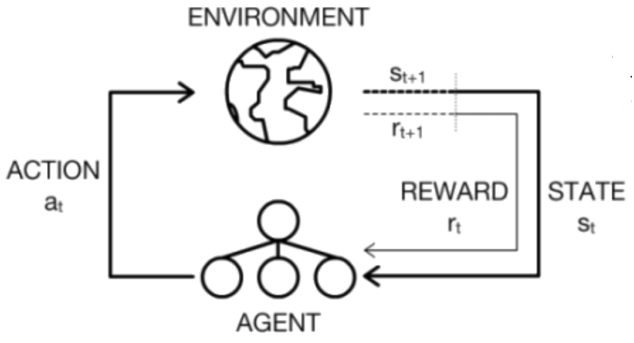

Reinforcement Learning

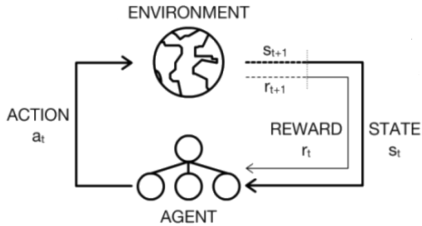

- s_t --- состояние среды (state);
- a_t --- действия агента (action);
- r_t --- награда (reward) за действие;

Reinforcement Learning

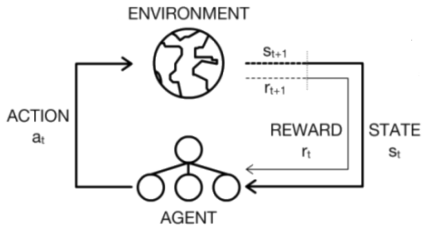

- $p(a \mid s)$ --- policy function, выводит вероятность действия в конкретном состоянии так, чтобы вероятность действия, максимизирующего reward была наибольшей
- $v(s)$ --- value function, по state выдаёт оценку всех будущих reward;
- $Q(s, a)$ --- Q-function, сообщает reward для действия a в состоянии s.

Reinforcement Learning

- Идея: мы пытаемся выразить действия агента с помощью различных функций. Если мы пытаемся каждую функцию представить в виде нейросетки, мы входим в зону deep reinfircment learning.

- В зависимости от того, какую функцию мы оптимизируем, получаем разные алгоритмы

- В примере ниже мы будем максимизировать policy function (policy gradient algorithm), после будем заниматься оптимизацией Q-функции (Q-learning)

Пример: игра в Pong

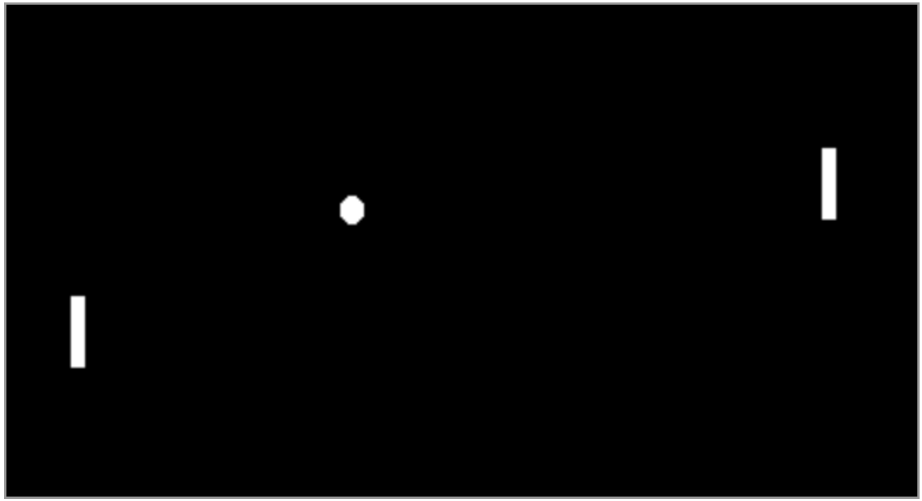

http://karpathy.github.io/2016/05/31/rl/

Пример: игра в Pong

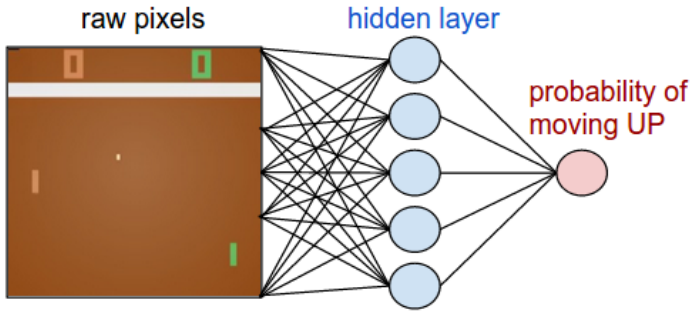

http://karpathy.github.io/2016/05/31/rl/

Пример: игра в Pong

- Хотим натренировать белую палку выигрывать!
- Состояние s_t --- пиксели экрана
- Мы хотим обучить нейросеть с одним скрытым слоем, которая по текущему дифу из пикселей предсказывать вероятность движения вверх или вниз
- Сеть сама пытается разобраться как правильно играть в эту игру на основе разницы между текущим и предыдущим кадром

Пример: игра в Pong

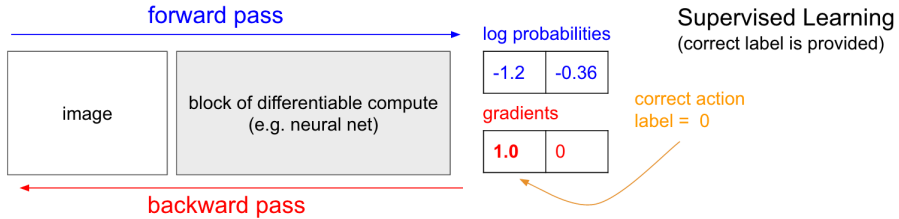

Пример: игра в Pong

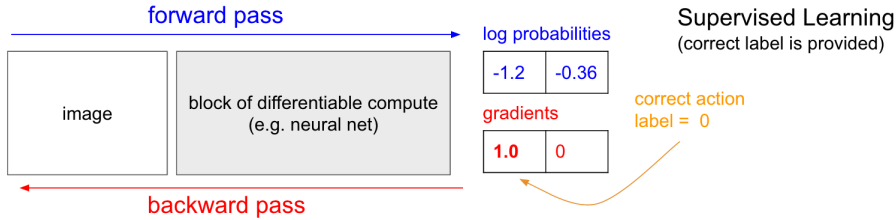

Пример: игра в Pong

- Если бы мы учили обычную сетку, у нас был бы вектор правильных ответов для каждого действия, и мы бы делали backpropagation
- На деле мы знаем результат после многих шагов
- Будем передавать вместо таргета то, что произошло на самом деле для последовательности действий

Пример: игра в Pong

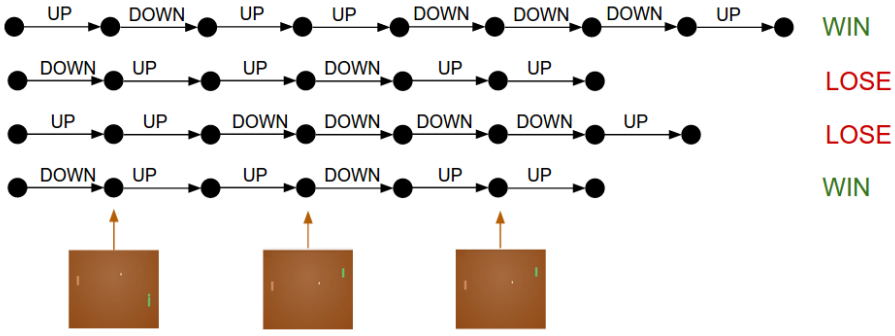

Почему это работает?

- Пусть $p(a \mid s, \theta)$ --- вероятность действия a в состоянии s, описываемая параметрами θ, а $f(a)$ --- награда от действия a
- Мы хотим двигать веса θ так, чтобы средняя награда $E_a[f(a)]$ увеличивалась
- Добиться этого можно с помощью градиентного спуска

Почему это работает?

$$\begin{aligned}
\nabla_\theta E_a[f(a)] &= \nabla \sum_a p(a) \cdot f(a) = \\
&= \sum_a \nabla_\theta p(a) \cdot f(a) = \\
&= \sum_a p(a) \cdot \frac{\nabla_\theta p(a)}{p(a)} \cdot f(a) = \\
&= \sum_a p(a) \cdot \nabla_\theta \ln p(a) \cdot f(a) = \\
&= E_a[f(a) \cdot \nabla_\theta \ln p(a) = -logloss
\end{aligned}$$

Какой бывает награда

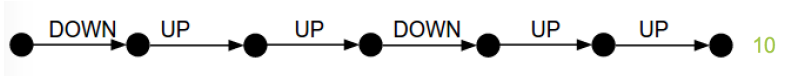

- В примере выше мы получали награду r за какую-то последовательность действий
- Можно определить награду так, что мы её получаем на каждом шаге r_t

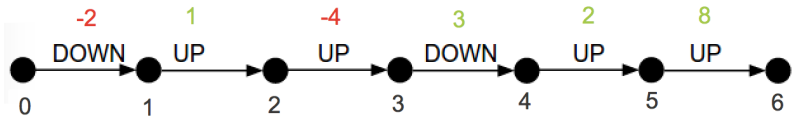

Какой бывает награда

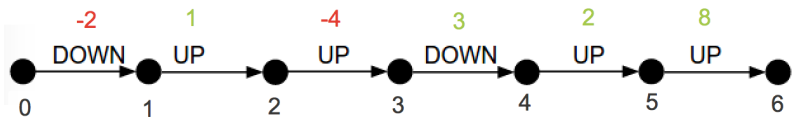

$$R_0 = r_0 + r_1 + r_2 + ... + r_h$$
$$R_0 = r_0 + \gamma \cdot r_1 + \gamma \cdot r_2 + ... + \gamma^h \cdot r_h$$

$$R_1 = r_1 + r_2 + ... + r_h ...$$
$$R_1 = r_1 + \gamma \cdot r_2 + ... + \gamma^{h-1} \cdot r_h ...$$

Какой бывает награда

Фактор дисконтирования γ нужен, чтобы очень далёкое будущее влияло на текущее состояние сети не так сильно, как в недалёком. Когда мы просим сеть разобраться с ближайшим будущим, ей легче разобраться в ситуации и обучение стабильнее.

Какой бывает награда

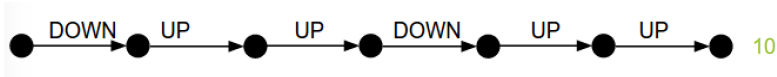

- В примере выше мы получали награду r за какую-то последовательность действий
- Можно определить награду так, что мы её получаем на каждом шаге r_t